


# Del Borde Discreto al Espacio Continuo

Redes Neuronales Informadas por la Física vs.  
Métodos Clásicos en la Ecuación de Calor 1D.

Emanuel Cabrera Novoa • Junio de 2025


Explorando la transición del cálculo numérico tradicional basado en mallas discretas hacia la modelación continua e integrable de sistemas físicos mediante redes neuronales profundas informadas por la física, enfocándose en la solución y análisis de la ecuación de calor unidimensional.

# Anatomía de una EDP: El Problema Físico



La dinámica global se rige por la difusión térmica ( $\alpha = 0.01 \text{ m}^2/\text{s}$ ), donde el calor fluye desde el pico central hacia los bordes fijos a temperatura cero.

# La Verdad Fundamental: Solución Analítica




$$u^*(x, t) = \exp(-\alpha\pi^2 t) \sin\left(\frac{\pi x}{L}\right)$$

Decaimiento en el tiempo (Disipación)


Conservación de la forma espacial

Mediante separación de variables, obtenemos una referencia matemática exacta.  
El calor decae exponencialmente mientras mantiene su perfil sinusoidal.  
Cualquier método numérico debe aspirar a replicar esta curva.

# El Retador Clásico: Método de Diferencias Finitas (FTCS)




Dominio **discretizado** en  $50 \times 100$  puntos espaciotemporales.



Esquema **explícito**:


$$u_i^{n+1} = u_i^n + r(u_{i-1}^n - 2u_i^n + u_{i+1}^n).$$



**Condición de Estabilidad de Von Neumann** exige número de Fourier  $r \leq 1/2$ .

El MDF transforma el espacio y el tiempo en una cuadrícula rígida. Es predecible y económico computacionalmente, pero vulnerable a errores de truncamiento espaciales  $O(\Delta x^2)$ .

# El Retador Moderno: Redes Neuronales Informadas por la Física



## ¿Por qué $\tanh$ y no ReLU?

El Teorema de Aproximación Universal nos permite usar la red como sustituto de la función real. Sin embargo, usar  $\tanh \in C^\infty(\mathbb{R})$  garantiza que las derivadas existan **sin discontinuidades**, algo que ReLU no puede lograr al tener una segunda derivada nula.

# Autograd vs. Truncamiento: El Cálculo de Derivadas

## MDF: El Pasado



**Diferencias Finitas.** Aproxima gradientes midiendo saltos entre nodos fijos. Acumula error de truncamiento estructural en cada paso.


## PINN: El Futuro



**Diferenciación Automática (Autograd).** Calcula la derivada analítica exacta a nivel de precisión de máquina aplicando la regla de la cadena en **reversa**. **Cero error de discretización.**



# La Función de Pérdida: Un Juego de Equilibrio Físico

$$L(\theta) = L_{\text{PDE}} + L_{\text{IC}} + L_{\text{BC}}$$



La optimización transforma un problema físico de valores de frontera en un juego de suma ponderada. La red aprende la física **penalizando la ignorancia.**


# La Carrera de Relevos de la Optimización



Adam mapea el paisaje general de los parámetros. **L-BFGS**, aproximando la matriz Hessiana, clava el descenso **logarítmico** al mínimo global hasta alcanzar  $\sim 10^{-7}$ .

# La Confrontación: Replicando la Disipación

Perfiles de Temperatura: Analítica vs MDF vs PINN




## Conclusión Visual: Éxito Absoluto

Ambos paradigmas logran capturar el decaimiento exponencial de la amplitud y la conservación de la curvatura sinusoidal a través del tiempo.

La red neuronal ha aprendido la física de la difusión sin necesidad de instrucciones geométricas paso a paso, logrando un mapeo perfecto de la dinámica.

# Radiografía del Error: La Curvatura Espacial



## Zona de Máxima Tensión Matemática

Los mayores errores (aprox.  $10^{-3}$ ) ocurren al inicio y en el centro exacto de la barra.

Físicamente, aquí es donde la curvatura espacial máxima y el residuo de la ecuación diferencial son más exigentes para la red neuronal.

# Análisis de Precisión a Través del Tiempo

|                                                                                                     | t = 0.0s                                              | t = 0.2s                                                                | t = 0.5s                                                                | t = 1.0s                                              |
|-----------------------------------------------------------------------------------------------------|-------------------------------------------------------|-------------------------------------------------------------------------|-------------------------------------------------------------------------|-------------------------------------------------------|
|  <b>MDF / FTCS</b> | $L_{\text{inf}}: \sim 10^{-3}$<br>$L_2: \sim 10^{-4}$ | $L_{\text{inf}}: \sim 10^{-3}$<br>$L_2: \sim 10^{-4}$                   | $L_{\text{inf}}: \sim 10^{-3}$<br>$L_2: \sim 10^{-4}$                   | $L_{\text{inf}}: \sim 10^{-3}$<br>$L_2: \sim 10^{-4}$ |
|  <b>PINN</b>      | $L_{\text{inf}}: \sim 10^{-3}$<br>$L_2: \sim 10^{-4}$ | $L_{\text{inf}}: \sim 8 \times 10^{-4}$<br>$L_2: \sim 6 \times 10^{-5}$ | $L_{\text{inf}}: \sim 4 \times 10^{-4}$<br>$L_2: \sim 2 \times 10^{-5}$ | $L_{\text{inf}}: \sim 10^{-3}$<br>$L_2: \sim 10^{-4}$ |


## MDF Insight

MDF: Mantiene un error uniforme en el tiempo, típico de la acumulación constante del error de truncamiento del esquema explícito FTCS.

## PINN Insight

PINN: Lucha ligeramente para capturar la condición inicial exacta en el interior, pero estabiliza su precisión a niveles idénticos al método clásico al converger.

# Matriz de Decisión Diagnóstica

|                        | MDF (FTCS)                                                                                                                | PINN                                                                                                                          |
|------------------------|---------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------|
| Naturaleza del Dominio |  Malla Discreta                        |  Espacio Continuo ( $C^\infty$ )           |
| Cálculo de Derivadas   |  Error de Truncamiento $O(\Delta x^2)$ |  Autograd Exacto                           |
| Estabilidad            |  Condicionada ( $r \leq 1/2$ )        |  Incondicionada                           |
| Output Final           |  Tabla de $51 \times 100$ valores    |  Función evaluable $\hat{u}(x,t;\theta)$ |
| Costo Computacional    |  Económico $O(N_x N_t)$              |  Entrenamiento Pesado                    |

Ambos alcanzan precisiones idénticas ( $10^{-3}$ ), pero ofrecen modelos operativos fundamentalmente distintos.

# Más Allá de la Barra 1D: Aplicaciones en el Mundo Real

## Ingeniería Térmica y Electrónica



Disipación de calor en microprocesadores. Las PINNs manejan geometrías de hardware complejas sin la necesidad de rediseñar pesadas mallas tridimensionales.

## Biofísica y Farmacología



Modelado de difusión de fármacos a través de membranas biológicas donde los coeficientes de difusión ( $\alpha$ ) varían espacialmente.

## Finanzas Cuantitativas



La ecuación de Black-Scholes para opciones financieras se transforma algebraicamente en una ecuación de calor. Las PINNs resuelven y calibran parámetros simultáneamente.

**La ventaja asimétrica:** Las PINNs sobresalen en problemas inversos (identificar parámetros ocultos a partir de datos dispersos) donde el MDF es ineficiente.

# Una Alianza Computacional, No un Reemplazo

## El Dominio del MDF

La herramienta definitiva para geometrías simples, simulaciones de avance rápido y escenarios donde la previsibilidad y el bajo costo computacional son prioritarios.



## La Frontera de las PINNs

La llave para el espacio continuo. Indispensable ante geometrías irregulares, datos escasos, problemas inversos y escenarios libres de mallas.

El Método de Diferencias Finitas discretiza la realidad para hacerla calculable. Las Redes Neuronales Informadas por la Física le enseñan a la máquina las leyes del universo para que extrapole lo continuo.